

Link Github : <https://github.com/nathannaelmoses/deeplearningaol.git>

I. EDA + Preprocessing

Dataset hanya mencakup satu kelas objek, yaitu plat nomor kendaraan, sehingga seluruh anotasi dalam dataset merepresentasikan objek yang sama. Kondisi ini secara otomatis mengeliminasi risiko class imbalance yang umumnya menjadi perhatian pada dataset multi-kelas.

```
=====
brightness      Mean=  109.90 | Min=   38.36 | Max=  200.03
contrast         Mean=   62.09 | Min=   38.76 | Max=   97.08
sharpness        Mean= 1707.64 | Min=  171.03 | Max= 5133.70
```

Analisis statistik dataset menunjukkan adanya variasi kualitas gambar yang cukup signifikan. Nilai Brightness Min sebesar 38.36 (dari skala 0–255) mengindikasikan bahwa sebagian gambar memiliki kondisi pencahayaan yang sangat rendah, sementara nilai Sharpness Min sebesar 171.03 yang diukur menggunakan metrik Laplacian variance menunjukkan adanya gambar dengan tingkat blur yang tinggi. Kedua kondisi ini, yaitu under-exposure dan blur, berpotensi menurunkan performa model karena fitur visual plat nomor seperti karakter dan batas tepi menjadi sulit dibedakan, sehingga model kesulitan menghasilkan prediksi bounding box yang akurat.

```
Metric      Min      Median      Mean      Max
width        640.00      640.00      640.00      640.00
height        640.00      640.00      640.00      640.00
aspect_ratio    1.00        1.00        1.00        1.00
megapixel      0.41        0.41        0.41        0.41
```

```
Resolusi unique : 1
```

Seluruh gambar dalam dataset telah memiliki dimensi yang seragam yaitu 640x640 piksel, sehingga proses resizing maupun padding manual tidak diperlukan. Standarisasi dimensi ini sangat menguntungkan karena YOLO secara native bekerja optimal pada input dengan ukuran tetap tanpa distorsi aspek rasio.

Untuk mengatasi masalah kualitas gambar yang ditemukan pada tahap EDA, diterapkan tiga tahap preprocessing secara berurutan. Pertama, perbaikan pencahayaan menggunakan CLAHE (Contrast Limited Adaptive Histogram Equalization) pada ruang warna LAB, dipilih karena peningkatan kontras hanya diterapkan pada kanal luminance sehingga warna asli gambar tetap terjaga. Kedua, penajaman adaptif menggunakan Unsharp Masking dengan intensitas yang disesuaikan secara dinamis berdasarkan skor Laplacian variance tiap gambar, sehingga gambar yang sudah tajam tidak mengalami

oversharpening. Ketiga, Global Contrast Stretch melalui normalisasi kanal warna untuk memastikan distribusi nilai piksel tersebar merata pada rentang 0 hingga 255 tanpa menggeser representasi warna aslinya.

Dataset awalnya dibagi dengan proporsi 80:10:10 untuk subset train, validasi, dan test. Namun karena dataset yang diperoleh dari Roboflow mencakup campuran gambar mobil dan motor, dilakukan proses filtering menggunakan YOLOv8 untuk memisahkan hanya gambar yang mengandung mobil. Akibat proses filtering ini, jumlah total data berkurang secara signifikan dan proporsi 80:10:10 yang sebelumnya sudah ditentukan menjadi tidak konsisten antar subset. Oleh karena itu, seluruh gambar hasil filtering digabungkan terlebih dahulu ke dalam satu folder master, kemudian di-split ulang dari awal dengan proporsi yang sama (80:10:10) untuk memastikan distribusi data yang merata dan konsisten di seluruh subset pelatihan.

II. The model chosen

A. Model 1 Vehicle Detection (YOLOv8)

Model pertama dalam pipeline adalah YOLOv8 yang bertugas mendeteksi keberadaan kendaraan (mobil) pada setiap frame gambar. YOLOv8 dipilih karena arsitekturnya yang dirancang untuk real-time inference, dengan keseimbangan yang baik antara kecepatan dan akurasi deteksi. Dibandingkan YOLOv11 yang secara arsitektur lebih kompleks, YOLOv8 menawarkan latency yang lebih rendah dan lebih stabil, yang menjadi pertimbangan utama mengingat pipeline ini dirancang untuk berjalan secara real-time.

B. Model 2 License Plate Detection (YOLOv8 + Transfer Learning)


Model kedua juga menggunakan YOLOv8, namun dikhususkan untuk mendeteksi dan melokalisasi koordinat plat nomor pada area kendaraan yang sudah teridentifikasi oleh model pertama. Model ini dilatih menggunakan anotasi koordinat plat yang disediakan langsung oleh Roboflow, dengan memanfaatkan transfer learning dari bobot pretrained YOLOv8 agar model dapat beradaptasi pada use case yang lebih spesifik dengan data yang lebih sedikit. Meskipun saat ini RF-DETR menjadi model SOTA untuk object detection, instabilitas latency-nya membuatnya kurang ideal untuk pipeline real-time, sehingga YOLOv8 tetap menjadi pilihan yang lebih pragmatis.

C. Model 3 OCR (EasyOCR)

Model ketiga adalah EasyOCR yang bertugas membaca karakter teks dari region plat nomor yang sudah terdeteksi. EasyOCR dipilih karena menggabungkan dua komponen deep learning secara end-to-end, yaitu CRAFT untuk mendeteksi area teks dan CRNN

untuk mengenali karakternya, tanpa memerlukan segmentasi karakter secara manual. Pendekatan ini membuat EasyOCR jauh lebih robust dibanding OCR konvensional seperti Tesseract dalam menghadapi kondisi gambar lapangan yang tidak ideal seperti blur ringan, kemiringan perspektif, dan variasi pencahayaan yang umum dijumpai pada kamera lalu lintas.

III. Training and validation results for Object Detection Plate Model



Box Loss

Menurun konsisten dan smooth dari awal hingga akhir training, baik pada train maupun val. Ini menunjukkan model semakin akurat dalam memprediksi koordinat dan ukuran bounding box plat nomor seiring bertambahnya epoch.

Classification Loss

Wajar kalau cls_loss turun sangat cepat dan mendekati nol karena dataset ini hanya memiliki satu kelas. Tidak ada ambiguitas klasifikasi yang perlu dipelajari model, sehingga loss ini bukan indikator utama performa model dalam konteks ini.

Distribution Focal Loss (DFL)



Penurunannya lebih lambat dibanding box loss, yang memang expected karena DFL bertugas mempelajari distribusi probabilitas lokasi tepi bounding box secara lebih presisi. Konvergensinya yang stabil di akhir epoch menunjukkan model sudah cukup baik dalam melokalisasi batas-batas plat nomor secara akurat.



Precision & Recall

Precision meningkat pesat di awal training dan stabil di kisaran 0.9 ke atas mulai sekitar epoch 20, sementara recall menunjukkan pertumbuhan yang lebih gradual namun tetap konsisten meningkat hingga akhir training. Pola ini menunjukkan model belajar menjadi presisi lebih dulu sebelum kemampuan recallnya menyusul, yang merupakan pola konvergensi yang sehat.

mAP50 & mAP50-95

mAP50 mencapai nilai mendekati 1.0 dan stabil di epoch-epoch akhir, mengindikasikan model sangat akurat dalam mendeteksi plat nomor pada threshold IoU 0.5. Sementara mAP50-95 konvergen di kisaran 0.7, yang tetap tergolong baik mengingat metrik ini jauh lebih sensitif terhadap ketepatan lokalisasi bounding box karena mengevaluasi pada rentang threshold yang lebih ketat.





Precision-Recall Curve ($\text{mAP}@0.5 = 0.981$)

Kurva PR berbentuk mendekati L terbalik sempurna, artinya model mampu mempertahankan precision di angka ~ 1.0 hingga recall mencapai sekitar 0.80 sebelum akhirnya turun tajam. Bentuk ideal ini menunjukkan model tidak perlu mengorbankan precision untuk mendapatkan recall yang tinggi, yang merupakan karakteristik model deteksi yang sangat baik.

Recall-Confidence Curve (Recall = 0.99 at 0.000)

Pada confidence threshold rendah, recall mencapai 0.99 artinya model hampir tidak pernah melewati plat nomor yang ada. Seiring naiknya confidence threshold, recall turun secara gradual dan baru drop signifikan di atas threshold 0.7. Ini berarti sebagian besar deteksi yang benar dilakukan dengan confidence yang cukup tinggi.


Precision-Confidence Curve (Precision = 1.00 at 0.864)


Precision mencapai 1.00 pada confidence threshold 0.864, artinya ketika model cukup "yakin" dengan prediksinya, hampir tidak ada false positive sama sekali. Bahkan di confidence rendah sekalipun, precision sudah berada di kisaran 0.8 ke atas, menunjukkan model sangat jarang salah mendeteksi objek yang bukan plat nomor.

F1-Confidence Curve (F1 = 0.95 at 0.514)


F1 score optimal sebesar 0.95 dicapai pada confidence threshold 0.514, yang merupakan titik keseimbangan terbaik antara precision dan recall. Kurva F1 yang lebar dan datar pada rentang confidence 0.3 hingga 0.7 menunjukkan model robust terhadap variasi threshold, sehingga tidak terlalu sensitif terhadap pemilihan confidence threshold dalam deployment.

Secara keseluruhan, keempat kurva secara konsisten mengonfirmasi bahwa model deteksi plat nomor ini memiliki performa yang sangat solid. Dengan mAP@0.5 sebesar 0.981, precision maksimal 1.00, recall 0.99, dan F1 optimal 0.95, model berhasil mencapai keseimbangan yang sangat baik antara ketepatan dan kelengkapan deteksi. Karakteristik kurva yang stabil pada berbagai rentang confidence threshold juga mengindikasikan model tidak overfitting terhadap threshold tertentu, sehingga fleksibel dan robust untuk digunakan pada kondisi nyata di lapangan.





Confusion matrix menunjukkan model berhasil mendeteksi 206 dari 210 plat nomor dengan benar (98%), sementara hanya 4 gambar yang mengandung plat nomor gagal terdeteksi sebagai false negative. Di sisi lain, terdapat 19 false positive di mana model salah mengidentifikasi area background sebagai plat nomor, namun jumlah ini relatif kecil dibanding total deteksi yang dilakukan. Secara keseluruhan, hasil ini selaras dengan nilai precision dan recall tinggi yang telah ditunjukkan pada kurva sebelumnya, mengonfirmasi bahwa model sangat andal dalam mendeteksi plat nomor pada berbagai kondisi gambar.




Dataset training mencakup total 1.731 instance plat nomor yang seluruhnya termasuk dalam satu kelas. Visualisasi distribusi koordinat pusat bounding box (scatter plot x,y) menunjukkan bahwa posisi plat nomor tersebar cukup merata di seluruh area gambar dengan sedikit konsentrasi di sekitar sumbu tengah horizontal ($x=0.4 - 0.6$), yang mencerminkan variasi sudut pengambilan gambar kendaraan yang cukup beragam. Sementara itu, distribusi ukuran bounding box (width vs height) menunjukkan bahwa sebagian besar plat nomor memiliki ukuran relatif kecil dalam frame, dengan width dominan di rentang 0.05 - 0.2 dan height di rentang 0.05 - 0.15, mengindikasikan bahwa plat nomor umumnya hanya menempati sebagian kecil dari keseluruhan area gambar. Visualisasi overlay bounding box pada pojok kanan atas juga mengonfirmasi bahwa plat nomor cenderung berbentuk persegi panjang horizontal dan terkonsentrasi di area tengah frame, konsisten dengan posisi plat nomor pada kendaraan yang umumnya berada di bagian depan atau belakang.

Training and Validation Summary

Model dilatih menggunakan 1.731 instance plat nomor dalam satu kelas dengan distribusi posisi dan ukuran bounding box yang cukup beragam, mencerminkan variasi kondisi pengambilan gambar yang realistis. Proses training selama 100 epoch berjalan dengan baik, ditandai oleh penurunan loss yang konsisten tanpa adanya divergensi antara train dan val loss, mengindikasikan model berhasil melakukan generalisasi tanpa overfitting.

Metrik validasi menunjukkan performa yang sangat solid dengan $mAP@0.5$ mencapai 0.981, precision maksimal 1.00, recall 0.99, dan F1 score optimal 0.95 pada confidence threshold 0.514. Kurva PR yang berbentuk mendekati L terbalik sempurna serta stabilitas performa pada berbagai rentang confidence threshold mengonfirmasi bahwa model tidak hanya akurat namun juga robust terhadap variasi kondisi inferensi, diperkuat oleh confusion matrix yang menunjukkan 206 dari 210 plat nomor berhasil terdeteksi dengan benar dengan hanya 4 missed detection dan 19 false positive.

IV. Evaluation results



F1-Confidence Curve (F1 = 0.96 at 0.258)

F1 score optimal sebesar 0.96 dicapai pada confidence threshold yang lebih rendah yaitu 0.258, sedikit lebih tinggi dibanding hasil validasi (0.95). Kurva yang lebar dan datar pada rentang confidence 0.2 hingga 0.7 menunjukkan model tetap robust terhadap variasi threshold, sehingga tidak sensitif terhadap pemilihan confidence threshold dalam deployment.

Precision-Recall Curve ($mAP@0.5 = 0.975$)



Kurva PR kembali menunjukkan bentuk mendekati L terbalik, dengan precision yang dipertahankan mendekati 1.0 hingga recall mencapai sekitar 0.90 sebelum akhirnya turun. $mAP@0.5$ sebesar 0.975 sedikit di bawah hasil validasi (0.981), namun selisih ini sangat kecil dan tidak signifikan secara praktis, mengindikasikan model berhasil mempertahankan performanya pada data test.

Precision-Confidence Curve (Precision = 1.00 at 0.873)

Precision mencapai 1.00 pada confidence threshold 0.873, konsisten dengan hasil validasi sebelumnya. Bahkan pada confidence rendah, precision sudah berada di kisaran 0.8 ke atas, menunjukkan model sangat jarang menghasilkan false positive pada data yang belum pernah dilihat sebelumnya.

Recall-Confidence Curve (Recall = 0.98 at 0.000)

Recall maksimal sebesar 0.98 pada confidence threshold rendah, sedikit turun dibanding validasi (0.99). Kurva menunjukkan recall tetap stabil di atas 0.90 hingga confidence threshold 0.7 sebelum drop signifikan, mengonfirmasi model sangat jarang melewatkan plat nomor pada kondisi inferensi nyata.



Confusion matrix pada data test menunjukkan model berhasil mendeteksi 217 dari 229 plat nomor dengan benar (95%), sementara 12 plat nomor gagal terdeteksi sebagai false negative dan 9 area background salah teridentifikasi sebagai plat nomor. Dibanding hasil validasi sebelumnya, terdapat sedikit penurunan pada recall (98% menjadi 95%) namun jumlah false positive juga berkurang dari 19 menjadi 9, menunjukkan model lebih konservatif dalam melakukan prediksi pada data test. Secara keseluruhan performa model pada data test tetap sangat baik dan konsisten dengan metrik yang sudah ditunjukkan

sebelumnya, mengonfirmasi bahwa model mampu melakukan generalisasi dengan baik terhadap data yang belum pernah dilihat sebelumnya.

Test Result



Summary

Model deteksi plat nomor ini secara keseluruhan menunjukkan performa yang sangat baik dan konsisten antara data validasi dan test, dengan $mAP@0.5$ 0.981 menjadi 0.975, precision tetap 1.00, dan recall 0.99 menjadi 0.98 penurunan yang sangat kecil dan tidak signifikan secara praktis. Trade-off yang terlihat adalah model sedikit lebih konservatif pada data test, di mana recall turun tipis namun false positive juga berkurang dari 19 menjadi 9, artinya model lebih "hati-hati" dalam melakukan prediksi pada data baru. Untuk konteks ganjil-genap, trade-off ini sebenarnya acceptable karena false positive (mendeteksi bukan plat sebagai plat) lebih berbahaya dibanding missed detection.

Dari sisi production readiness, model ini sudah layak untuk di-deploy dengan beberapa catatan. Pertama, performa model sangat bergantung pada kualitas input dari pipeline sebelumnya jika vehicle detection model gagal crop area kendaraan dengan benar, plate detection model juga akan ikut terdampak. Kedua, missed detection masih terjadi pada plat yang sangat kecil atau jauh dari kamera, yang bisa menjadi masalah pada skenario CCTV dengan jarak pengambilan gambar yang bervariasi. Ketiga, akurasi OCR end-to-end belum dievaluasi secara kuantitatif, sehingga meskipun deteksi bounding box sudah solid, belum ada jaminan bahwa teks plat terbaca dengan benar secara konsisten untuk klasifikasi ganjil-genap.

Kesimpulannya, model ini merupakan good fit untuk use case yang dimaksud, namun deployment production yang benar-benar robust idealnya masih memerlukan evaluasi end-to-end accuracy dari deteksi hingga pembacaan OCR dan klasifikasi ganjil-genap sebagai satu pipeline utuh.

Final Prediction Result



OCR Result 1: SAA-6520

```
=====
OCR RESULT      : SAA-6520
LAST DIGIT      : 0
PLATE STATUS    : EVEN
DECISION        : ALLOWED (Date: 8 [EVEN], Plate: EVEN)
=====
```

=== PIPELINE DONE ===

Hasil Deteksi: B 1429 SJUI



```
image 1/1 C:\Adhika\Deep Learning\ yol_deeplearning\deeplearning yol_model\after-resplit-vehicle-dataset\test\images\crv16.jpg.rf.ee673d8eba1ff374ff0ccfc811e8d55a.jpg: 640x640 1 plate, 7.7ms  
Speed: 2.4ms preprocess, 7.7ms inference, 10.4ms postprocess per image at shape (1, 3, 640, 640)  
OCR Result 1: B 1429 SJUI
```

```
=====
OCR RESULT      : B 1429 SJUI
LAST DIGIT      : 9
PLATE STATUS     : ODD
DECISION         : VIOLATION - CANNOT PASS (Date: 8 [EVEN], Plate: ODD)
=====
```


Hasil Deteksi: D 1429 AY



```
image 1/1 C:\Vdhika\Deep Learning\ao1_deeplearning\deeplearningao1\model\after-resplit-vehicle-dataset\test\images\plat-475-  
_jpg.rf.21c593aa701ae3533fb015b41aa97ba7.jpg: 640x640 1 plate, 8.4ms  
Speed: 2.5ms preprocess, 8.4ms inference, 10.7ms postprocess per image at shape (1, 3, 640, 640)  
OCR Result 1: D 1429 AY
```

```
=====
OCR RESULT      : D 1429 AY
LAST DIGIT      : 9
PLATE STATUS     : ODD
DECISION         : VIOLATION - CANNOT PASS (Date: 8 [EVEN], Plate: ODD)
=====
```

Existing challenges or future opportunities

Tantangan yang Dihadapi

1. Beberapa gambar kendaraan tidak menampilkan objek secara utuh, seperti mobil yang hanya terlihat bagian rodanya atau motor yang terpotong sebagian, sehingga model kesulitan melakukan klasifikasi kendaraan dengan akurat.
2. Banyak gambar memiliki resolusi rendah, buram, gelap, atau noisy sehingga karakter pada plat nomor sulit dibaca, yang berdampak langsung pada menurunnya akurasi OCR dan performa sistem deteksi ganjil-genap secara keseluruhan.
3. Gambar kendaraan yang diambil dari sisi samping kiri atau kanan menyebabkan posisi plat nomor tidak terlihat jelas, sehingga proses deteksi plat gagal meskipun kendaraan berhasil dikenali oleh model.
4. Beberapa gambar memuat lebih dari satu kendaraan dalam satu frame, seperti mobil dan motor secara bersamaan, sehingga model berpotensi mendeteksi dan membaca plat nomor kendaraan yang bukan target utama, mengakibatkan hasil prediksi yang tidak konsisten.

Rekomendasi

1. Menerapkan cropping area kendaraan sebelum masuk ke tahap deteksi plat agar model lebih fokus pada objek utama dan mengurangi gangguan dari objek lain di sekitar frame, sekaligus meningkatkan akurasi deteksi plat secara keseluruhan.
2. Memprioritaskan penggunaan gambar kendaraan dari sisi depan atau belakang dalam dataset agar plat nomor selalu terlihat jelas, sekaligus meminimalkan gambar dari sisi samping yang tidak relevan untuk proses deteksi plat.
3. Memperbesar jumlah dataset hingga 5.000–10.000 gambar dengan kualitas resolusi yang lebih baik, agar model memiliki variasi data yang lebih luas selama training dan karakter plat nomor dapat terbaca lebih akurat oleh model OCR.
4. Mengembangkan pipeline lebih lanjut dengan menambahkan tahap klasifikasi kendaraan listrik dan non-listrik, mengingat di beberapa negara kendaraan listrik dikecualikan dari aturan ganjil-genap.
5. Melakukan perbandingan performa dengan model pretrained lain seperti Faster R-CNN, SSD (Single Shot MultiBox Detector), dan RetinaNet untuk mendapatkan referensi yang lebih komprehensif dan memastikan YOLOv8 merupakan pilihan yang paling optimal untuk use case ini.